

COMPARATIVO BASELINE VS ACTUAL Y EVALUACIÓN DE LATENCIA

Seminario de Tesis 2 - Sprint 10

**Aplicación de modelos de IA para la detección proactiva de fallas físicas en
infraestructura de red NOC**

Autor: Fernando Joel Blaz Aleman

Docente/asesor: PhD. Glen Darío Rodríguez Rafael

Fecha: 10 de julio de 2026

Alcance de esta entrega

Comparación técnica leakage-safe, p50/p95/p99, throughput, errores, optimizaciones, evidencias reproducibles y protocolo de percepción del stakeholder. Las respuestas de usuario no se fabrican: permanecen pendientes de ejecución real.

1. Resumen ejecutivo

Decisión recomendada

GO para laboratorio y shadow mode. NO-GO para canary o producción con impacto real hasta validar percepción con usuarios NOC, acordar el costo FN/FP y cerrar los riesgos críticos.

El modelo actual mejora la priorización respecto de la regla BAU en F1, precisión, Average Precision, Brier y carga de alertas. Sin embargo, reduce el recall. Por ello la conclusión no es “el modelo gana en todo”, sino que ofrece una mejor relación entre carga operativa y cobertura bajo el costo asumido $FP + 3 \cdot FN$.

Indicador	Baseline BAU	Actual	Lectura
F1	0.492	0.503	Mejora 2.2%
Precisión	0.329	0.346	Mejora 1.6 pp
Recall	0.973	0.925	Pierde 4.9 pp
Average Precision	0.356	0.435	Mejora 22.2%
Brier (menor mejor)	0.428	0.221	Reduce 48.3%
FP	1420	1254	Reduce 166 (11.7%)
FN	19	54	Costo: +35 casos
Costo $FP+3FN$	1477	1416	Reduce 61 (4.1%)




Figura 1. Métricas del holdout cronológico. Fuente: ejecución reproducible de Sprint 10.

2. Diseño de la evaluación

Se utilizó el dataset anonimizado de Sprint 7 y se ordenó por año, semana ISO, día y hora. Los timestamps iguales se mantuvieron en la misma partición para evitar contaminación temporal.

Partición	n	Positivos	Inicio	Fin
train	7566	32.6%	2024-01-01 05:00	2025-09-24 04:00
calibration	1079	28.5%	2025-09-24 05:00	2025-12-08 08:00
test	2161	33.1%	2025-12-08 11:00	2026-04-24 11:00

Baseline y modelo actual

Baseline operacional: regla BAU congelada de Sprint 7, umbral 0.50. Se eligió porque el material de clase permite usar BAU o una regla vigente cuando representa la decisión actual del stakeholder.

Modelo actual: regresión logística con one-hot, imputación entrenada solo en train, $C=1.0$, sin `class_weight`. El umbral 0.245 se fijó únicamente en calibración.

Selección: minimizar $FP + 3 \cdot FN$ con recall de calibración ≥ 0.85 . Entre configuraciones a $\leq 2\%$ del costo mínimo se eligió la de menor Brier. El holdout se abrió una sola vez.

Auditoría crítica de fuga

El modelo Sprint 8 usaba `duration_hours_evidence`. Como `label_over_ola` se construye a partir de la duración final frente al OLA/SLA, esa variable no existe al abrir el incidente y filtra la respuesta. Sprint 10 bloquea duración final, fecha de cierre, tiempo de resolución y `label_source`.




Figura 2. La duración final está fuertemente asociada con la etiqueta; se conserva solo como evidencia de auditoría.

3. Latencia, capacidad y robustez

El protocolo separó carga fría, servicio caliente y micro-batching. Se usó `time.perf_counter_ns`, warmup explícito y múltiples repeticiones. Los resultados son del hardware registrado en el manifiesto y no deben extrapolarse sin repetir en el servidor objetivo.

Modo	Batch	p50 ms	p95 ms	p99 ms	req/s
Cold/carga por llamada	1	10.275	12.315	12.586	96.2
Warm/precargado	1	7.917	9.919	10.653	123.8
Warm/precargado	8	7.136	7.759	8.296	1115.2
Warm/precargado	16	6.852	7.350	8.261	2302.5
Warm/precargado	32	6.943	7.583	8.032	4547.8
Warm/precargado	64	7.277	7.904	7.977	8737.8




Figura 3. Latencia p50/p95 por modo. El SLO de laboratorio es p95 <150 ms.

Resultado SLO

Warm batch 1: p50 7.917 ms, p95 9.919 ms y 123.8 req/s. Batch 16: 2302.5 req/s con p95 de lote 7.350 ms. Error interno observado: 0%.

Optimizaciones probadas

- **Carga fría vs precarga:** Mantener el joblib en memoria redujo p95 y elevó throughput. Cargar por request se clasifica como antipatrón.
- **Micro-batching:** Lotes 8-16 amortizan el costo fijo y son la recomendación para una cola; batch 1 sigue siendo apropiado para interacción.
- **Validación vectorizada:** Tipos, rangos y campos obligatorios se verifican antes de inferencia. Categorías nuevas son toleradas por OneHotEncoder.
- **No probadas en esta entrega:** ONNX/GPU/TensorRT no se justificaron para un modelo lineal pequeño; primero se optimizó el cuello real: carga y batching.

Pruebas de robustez

Se ejecutaron 8 casos: entrada válida, campo requerido ausente, tipo numérico inválido, rango imposible, categoría desconocida, campo extra, nulo categórico y lote vacío. Resultado: 8/8 correctos; 0 errores internos.

4. Percepción del usuario y decisión de despliegue

Estado de evidencia de usuario

No se encontraron respuestas reales de stakeholders en los archivos entregados. Se prepararon protocolo A/B, tres escenarios, hoja de facilitación, plantilla CSV y agregador. Reportar valores ficticios dañaría la validez de la tesis.

Las dimensiones pendientes son utilidad, claridad, confianza, éxito de tarea, tiempo y riesgos de “nunca usaría”. El criterio mínimo propuesto para canary es $n \geq 3$ usuarios NOC, mediana $\geq 4/5$ en utilidad y claridad, éxito $\geq 80\%$, sin riesgo crítico abierto y aceptación explícita del trade-off FN/FP.

Matriz de decisión

Etapas	Decisión	Condición	Rollback
Laboratorio	GO	Evidencia reproducible y pruebas 8/8	No aplica
Shadow mode	GO condicionado	Logging, revisión de FN, sin afectar decisiones	Regla BAU
Canary / producción	NO-GO	Falta percepción real y acuerdo de costo	Regla BAU + desactivar modelo

5. Conclusiones

1. La mejora técnica es moderada pero defendible: F1 +0.011, AP +0.079, Brier -0.206, 166 FP menos y costo ponderado 61 casos menor.
2. El costo de esa reducción es 35 FN adicionales y -4.9 pp de recall; el modelo no debe operar sin supervisión.
3. El sistema cumple holgadamente el SLO de laboratorio con modelo precargado y error interno observado de 0%.
4. La corrección de target leakage es más importante que preservar la métrica histórica de Sprint 8.
5. El siguiente paso válido es una prueba A/B con usuarios NOC y luego shadow mode instrumentado.

6. Evidencia entregada

- Script principal, contrato de inferencia, agregador de stakeholder y 8 pruebas unitarias.
- Notebook ejecutado, predicciones del holdout, muestras de latencia, eventos y manifiesto de hardware/versiones.
- Tablas CSV: comparativo, IC95 bootstrap, sensibilidad de umbral, latencia, optimizaciones, robustez y auditoría de fuga.
- Figuras: baseline vs actual, Precision-Recall, umbral, latencia, throughput y fuga.
- Artefacto joblib y model card; protocolo y plantillas de stakeholder.

Referencias internas

- Material de clase: Maestria2_IA12.pptx, “Prueba con stakeholder y latencia”.
- Repositorio: Fer-ds/tesis-noc-fallas-ia, rama seminario-tesis2-matriz-sprint8.
- Entregables Sprint 7 HPO, Sprint 8 MLOps/overfitting y Sprint 9 error slicing incluidos en los archivos fuente.
- Evidencia Sprint 10 generada el 10 de julio de 2026; versiones y hashes en artifacts/reproducibility_manifest_sprint10.json.