

Matriz de Consistencia

Modelos de inteligencia artificial para la detección proactiva de fallas físicas en infraestructura de red de telecomunicaciones en entornos NOC

Problema / pregunta general	¿En qué medida un pipeline reproducible de IA, entrenado con incidentes históricos NOC TX/IP, permite detectar proactivamente incidentes con riesgo de incumplir OLA (Over OLA) y sostener su desempeño bajo validación temporal?
Objetivo general	Desarrollar, optimizar y validar un pipeline de IA para clasificar incidentes NOC TX/IP como Over OLA u On Time, utilizando variables operativas y temporales, validación temporal y MLOps ligero para asegurar trazabilidad y control de sobreajuste.
Hipótesis general	Un pipeline de IA con variables operativas y temporales, evaluado con validación temporal y trazabilidad MLOps, permite detectar incidentes con riesgo de Over OLA con desempeño medible en F1/precision/recall y con control explícito del gap train-validación.
Base Sprint 8	10,819 incidentes válidos; 3,505 Over OLA; 7,314 On Time; tasa positiva 32.4%; 44 branches anonimizados; rango 2022-08-14 a 2026-04-24. Target: label_over_ola. Validación: TimeSeriesSplit(n_splits=3), seed=42. Métrica principal: F1 de validación temporal.

Tabla 1. Matriz de consistencia por objetivos específicos

Objetivo específico	Hipótesis específica	Variable independiente (VI)	Variable dependiente (VD)	Variables de control	Operacionalización: indicadores y escala	Evidencia / instrumento Sprint 8
OE1. Evaluar el desempeño predictivo del pipeline de IA para clasificar incidentes NOC como Over OLA u On Time.	H1. Las configuraciones de IA con todas las variables operativas y temporales obtienen mejor desempeño de validación temporal que configuraciones parciales o no optimizadas.	Condición experimental del modelo/pipeline: tipo de modelo y configuración de hiperparámetros. Ej.: RandomForest baseline vs GradientBoostingClassifier optimizado; threshold de decisión.	Desempeño predictivo para la clase crítica Over OLA.	Mismo dataset anonimizado, mismo target label_over_ola, misma partición temporal, mismo seed=42, mismo preprocesamiento base (imputación y codificación), mismas métricas.	Dimensión: desempeño de clasificación. Indicadores: F1 de validación temporal, precision, recall, average precision, balanced accuracy y Brier. Escala: razón 0-1. Criterio central: F1 porque balancea precision y recall en clase desbalanceada.	Dashboard de corridas Sprint 8. Referencias: RF all features F1_val≈0.6096; GBC HPO all features F1_val≈0.5796. Modelo Sprint 7: GradientBoostingClassifier + OrdinalEncoder + SimpleImputer, Trial 8 Random Search.
OE2. Determinar qué grupos de variables mueven la métrica mediante ablaciones controladas.	H2. El uso conjunto de variables operativas y temporales aporta más información que usar solo variables temporales o solo núcleo operativo sin tiempo; retirar branch_id o reason_group produce variaciones menores frente a retirar grupos completos.	Set de variables usado en cada corrida: todas las features; sin branch_id; sin reason_group; solo temporales; operativas sin tiempo.	Cambio en desempeño por ablación.	Mismo modelo para las ablaciones controladas, mismo split temporal, mismo seed, misma métrica, mismo threshold del HPO para las variantes GradientBoosting.	Dimensión: contribución de variables. Indicadores: delta F1 vs all features, delta average precision, número de features. Escala: razón/intervalo según delta. Comparación principal: F1_val_mean y delta_f1_vs_all_features.	Ablation summary Sprint 8. Referencias: GBC all features F1_val≈0.5796; sin reason_group≈0.5780; sin branch_id≈0.5780; operativas sin tiempo≈0.4943; solo temporales≈0.4896.
OE3. Controlar el riesgo de sobreajuste y dejar el experimento trazable para defensa y reproducción.	H3. El pipeline con validación temporal, regularización, early stopping/pruning y registro MLOps mantiene un gap train-validación controlado y permite reproducir las corridas sin exponer datos sensibles.	Mecanismo de control experimental: TimeSeriesSplit, early stopping, pruning/ccp_alpha, threshold documentado y artefactos MLOps.	Gap de sobreajuste y trazabilidad del experimento.	Datos anonimizados, exclusión de TTWO/coordenadas/link name/tracking incident, mismo repositorio, carpetas config/logs/results/artifacts/src/notebooks/docs.	Dimensión: generalización interna y reproducibilidad. Indicadores: gap = F1_train_mean - F1_val_mean; existencia de logs, manifest, modelo joblib, dashboard, ablation_summary y overfitting report. Escala: gap en razón/intervalo; trazabilidad nominal sí/no.	Reportes Sprint 8: overfitting_gap_sprint8.csv, mlops_runs_sprint8.csv, model card y README patch. Referencia: GBC HPO gap≈0.0394; RF baseline gap≈0.1316.

Plan de generalización fuera de la muestra / Plan B

Escenario	Acción propuesta	Indicador / evidencia
Holdout temporal externo	Congelar el pipeline e hiperparámetros ganadores y reservar una ventana posterior de incidentes NOC como prueba fuera de muestra. No hacer fit global con datos externos.	Tabla CV temporal vs holdout externo con F1, precision, recall, average precision, Brier, curva PR y calibración.
Si no hay datos externos suficientes	Aplicar Plan B con backtesting temporal, Group/LOGO por branch operativo y pruebas de robustez con missingness/ruido controlado.	Tabla por ventana/grupo, delta de métrica, top variables con shift y breve explicación de degradación.

Shadow mode operativo	Ejecutar el modelo en sombra sobre logs o alarmas recientes sin afectar decisiones de operación.	Predicciones registradas, tasa de alertas, falsos positivos estimados y plan de ajuste de threshold/calibración.
-----------------------	--	--